Assignment #2 Report
DeepXplore-style Differential Testing on CIFAR-10

2021550014 서종석

April 19, 2026

1 Introduction

이번 과제에서는 DeepXplore의 핵심 아이디어인 differential testing을 CIFAR-10 분류 문제에 적용하였다. DeepXplore는 동일한 입력을 여러 신경망에 동시에 넣고, 그 예측이 서로 달라지는 경우를 suspicious input으로 간주하는 white-box testing 방법이다. 또한 단순히 예측 불일치만 찾는 것이 아니라, 테스트 과정에서 더 많은 내부 뉴런이 활성화되도록 하여 neuron coverage를 높이는 것도 중요한 목표로 한다.

실험에서는 CIFAR-10에 대해 학습된 두 개의 ResNet50 모델을 준비하였다. 이후 동일한 test input에 대해 두 모델의 예측을 비교하여 baseline disagreement를 측정하였고, 그 다음 gradient 기반 입력 생성을 통해 이러한 disagreement를 유지하거나 강화하는 과정을 수행하였다. 또한 생성 전후의 neuron coverage를 측정하여, 입력 생성이 모델 내부 활성 패턴의 다양성에도 영향을 주는지 함께 확인하였다.

2 Problem 1: Differential Testing with DeepXplore

2.1 Experimental Setup

두 모델이 의미 있는 differential testing의 대상이 되도록 학습 설정을 다르게 구성하였다. Model A는 SGD와 기본 augmentation을 사용해 학습했고, Model B는 AdamW와 더 강한 augmentation을 사용해 학습하였다. 이렇게 함으로써 전체 정확도는 비슷하더라도, 국소적인 decision boundary와 입력에 대한 민감도는 다르게 형성될 수 있도록 했다.

이후 평가 단계는 두 부분으로 나누어 수행하였다. 먼저 CIFAR-10 test set 전체를 대상으로 두 모델의 baseline disagreement를 측정하였다. 다음으로, 이미 disagreement가 발생한 seed 입력들 중 일부를 선택하고, gradient 기반 입력 생성 절차를 통해 그 불일치를 유지하거나 강화하는 실험을 수행하였다. 이 과정에서 convolution layer와 linear layer의 activation을 기준으로 neuron coverage를 계산하였다.

2.2 Model Performance and Baseline Disagreements

먼저 두 모델의 전체 성능과 baseline disagreement를 확인하였다. 전체 정확도는 비슷한 수준이었지만, test set에서는 상당한 수의 예측 불일치가 관찰되었다. 이는 overall accuracy만으로는 드러나지 않는 local sensitivity 차이가 존재함을 보여준다. 또한 이후의 gradient 기반 단계는 이러한 baseline disagreement를 새로 만드는 과정이라기보다, 이미 관찰된 불일치를 유지하거나 더 뚜렷하게 드러내는 과정으로 해석하는 것이 적절하다.

Table 1: 두 모델의 기본 성능 및 baseline disagreement 결과

항목	결과
Model A test accuracy	89.01%
Model B test accuracy	88.20%
Baseline disagreement 개수	1183

두 모델은 전체 정확도 차이가 크지 않았음에도 불구하고 1183개의 입력에서 서로 다른 예측을 보였다. 이는 독립적으로 학습된 두 모델이 동일한 입력 공간을 서로 다르게 분할하고 있음을 시사한다. 따라서 baseline disagreement 자체만으로도 differential testing의 출발점으로서 충분한 의미를 가진다고 보았다.

2.3 Generated Disagreement Cases

이후 baseline disagreement가 발생한 입력들 중 일부를 seed로 선택하여 gradient 기반 입력 생성을 수행하였다. 생성 과정의 목적은 두 모델의 예측 불일치를 유지하거나 강화하면서, 동시에 더 다양한 내부 뉴런 활성 패턴을 유도하는 것이었다.

Table 2: Generated disagreement 실험 개요

항목	결과
선택한 seed 개수	20
Success로 기록된 사례 수	20 / 20
저장한 대표 generated 이미지 수	5

실험에서는 총 20개의 baseline disagreement seed를 선택하였다. 즉, 처음부터 두 모델의 예측이 서로 다른 입력들만 골라 후속 gradient 기반 갱신을 적용하였다. 실행 로그 기준으로 20개 사례 모두에서 최종적으로도 두 모델의 예측 불일치가 유지되었으며, 각 사례는 `success=True`로 기록되었다. 이는 선택한 seed 입력들이 이미 두 모델의 경계적 차이를 잘 드러내고 있었고, gradient 기반 갱신이 그 차이를 유지하는 방향으로 작동했음을 보여준다.

2.4 Neuron Coverage

이번 구현에서는 convolution layer와 linear layer의 activation을 이용하여 neuron coverage를 측정하였다. Conv2d layer의 경우 spatial mean을 기준으로 channel activation을 요약하였고, Linear layer의 경우 각 뉴런의 출력을 그대로 사용하였다. activation이 임계값을 넘은 경우 해당 뉴런이 활성화된 것으로 간주하였다.

대표적인 seed들의 coverage 변화는 다음과 같았다.

Table 3: 대표적인 generated seed들의 neuron coverage 변화

Seed 번호	Before	After	변화량
1	0.4110	0.4164	+0.0054
2	0.4016	0.3987	-0.0029
3	0.4043	0.4097	+0.0054
4	0.4180	0.4224	+0.0044
5	0.3956	0.3984	+0.0028

전체 20개 seed에 대한 coverage 통계는 다음과 같이 요약할 수 있었다.

Table 4: 20개 generated seed에 대한 coverage 요약

항목	결과
평균 coverage (before)	0.3992
평균 coverage (after)	0.4015
Coverage 증가 사례 수	15 / 20
Coverage 감소 사례 수	5 / 20

전체 20개 사례 중 15개에서는 coverage가 증가했고 5개에서는 감소하였다. 따라서 coverage는 전반적으로 소폭 증가하는 경향을 보였지만, 모든 사례에서 일관되게 증가한 것은 아니었다. 그러므로 현재 구현은 DeepXplore의 핵심 아이디어를 반영한 초기 형태라고 보는 것이 적절하다고 판단하였다.

2.5 Discussion

우선 두 모델의 전체 정확도는 89.01%와 88.20%로 비슷한 수준이었지만, baseline disagreement는 1183개나 관찰되었다. 이는 overall accuracy만으로는 드러나지 않는 local sensitivity의 차이가 실제로 존재함을 보여준다. 즉, 두 모델은 전체적으로는 비슷한 성능을 보이지만, 특정 입력 근처의 decision boundary는 다르게 형성되었을 가능성이 높다.

또한 generated disagreement 사례들을 보면 ship–automobile, bird–deer, cat–bird, truck–airplane과 같이 시각적으로 다소 유사하거나 경계적인 클래스 조합이 반복적으로 나타났다. 이는 CIFAR-10의 클래스 구조상 자연스러운 현상이라고 볼 수 있으며, differential testing이 이런 애매한 입력들을 효과적으로 드러낸다고 해석할 수 있었다.

마지막으로 neuron coverage는 대체로 증가하는 경향을 보였으나, 모든 사례에서 일관되게 증가하지는 않았다. 따라서 이번 구현은 DeepXplore의 핵심 아이디어를 현재 환경에 맞게 단순화하여 반영한 초기 형태라고 보는 것이 적절하다. 그럼에도 불구하고 baseline disagreement 탐색, gradient 기반 입력 생성, neuron coverage 측정이 하나의 파이프라인으로 연결되었다는 점에서 과제의 목적에는 충분히 부합한다고 판단하였다.

3 Problem 2: Connecting Attacks and Testing

Assignment 1에서 구현했던 FGSM과 PGD는 입력에 작은 perturbation을 가해 모델의 예측을 변화시키는 대표적인 adversarial attack 기법이었다. 반면 DeepXplore는 동일한 입력을 여러 모델에 동시에 적용하고, 그 예측이 서로 달라지는 경우를 suspicious input으로 간주하는 differential testing 방법이다. 두 접근은 표면적으로는 attack과 testing이라는 차이가 있지만, 공통적으로 모델이 취약한 입력 영역을 드러낸다는 점에서 연결될 수 있다.

가장 직접적인 결합 방식은 adversarial attack을 differential testing의 seed generation 도구로 사용하는 것이다. FGSM이나 PGD는 입력을 decision boundary 근처의 민감한 방향으로 빠르게 이동시키므로, clean input보다 여러 모델 사이의 disagreement를 더 쉽게 드러낼 가능성이 있다. 특히 서로 다른 초기값, optimizer, augmentation으로 학습된 모델들은 경계 근처에서 서로 다른 local sensitivity를 보일 수 있으므로, attack으로 생성한 입력을 seed로 사용하면 DeepXplore-style testing이 더 빠르게 suspicious case를 찾을 수 있다고 생각했다. 이런 의미에서 공격은 상태 공간 안에서 빠른 이동을 제공하고, testing은 그 이동이 의미 있는 취약 영역을 향하도록 제약을 주는 역할을 한다고 볼 수 있다.

물리적으로 비유하면, 입력은 하나의 상태이고 각 모델은 그 상태에 대해 서로 다른 에너지 지형을 갖는 시스템으로 해석할 수 있다. 이때 adversarial attack은 gradient를 따라 상태를 빠르게 이동시키는 외부 perturbation에 가깝고, DeepXplore는 여러 에너지 함수 사이에서 불안정한 영역을 탐색하는 과정과 유사하다. 또한 neuron coverage를 함께 고려하는 것은 단순히 한 상태에서 다른 상태로 이동하는 것이 아니라, 시스템의 더 다양한 내부 자유도를 활성화하도록 유도하는 것으로 볼 수 있다.

이 관점에서 coverage-guided attack은 매우 자연스럽다. 기존 FGSM이나 PGD가 주로 misclassification만을 목표로 했다면, 여기에 neuron coverage 항을 추가하는 것은 모델이 특정한 좁은 활성 패턴에만 머무르지 않고 더 넓은 내부 상태 공간을 탐색하도록 만드는 것이다. 따라서 attack objective와 testing objective를 결합하면, failure를 더 빨리 찾으면서도 더 다양한 내부 동작을 관찰할 수 있는 hybrid framework를 구성할 수 있다고 본다. 이는 단순한 perturbation이나 단순한 random testing보다 효율적으로 bug를 찾게 만들 가능성이 있다.

다만 이러한 결합이 항상 유리한 것은 아니다. Adversarial attack은 본질적으로 국소적인 gradient 정보에 크게 의존하므로, global exploration보다 특정 local basin에 과도하게 머무를 수 있다. 또한 neuron coverage가 증가했다고 해서 그것이 곧 의미 있는 semantic bug를 발견했다는 뜻은 아니며, 모델 간 disagreement 역시 항상 실제 오류를 보장하지 않는다. 따라서 attack과 testing의 결합은 매우 유망하지만, 이를 만능 해결책으로 보기보다는 구조화된 취약점 탐색을 가속하는 방법으로 이해하는 것이 더 적절하다고 판단했다.

4 Conclusion

이번 과제에서는 DeepXplore의 핵심 아이디어를 CIFAR-10용 ResNet50 두 모델에 적용하여 differential testing을 수행하였다. 두 모델은 test set에서 1183개의 baseline disagreement를 보였고, 선택한 20개의 seed 입력에 대해서는 gradient 기반 생성 이후에도 모두 예측 불일치가 유지되었다. 또한 neuron coverage는 전반적으로 소폭 증가하는 경향을 보였다.

전체적으로 이번 실험은 differential testing이 단순 accuracy 평가만으로는 드러나지 않는 모델의 국소적 취약성을 드러내는 데 효과적임을 보여주었다. 또한 DeepXplore-style 접근이 현재의 PyTorch 기반 환경에서도 충분히 재구성 가능하며, 모델 간 차이를 분석하는 유용한 테스트 프레임워크로 활용될 수 있음을 확인하였다.